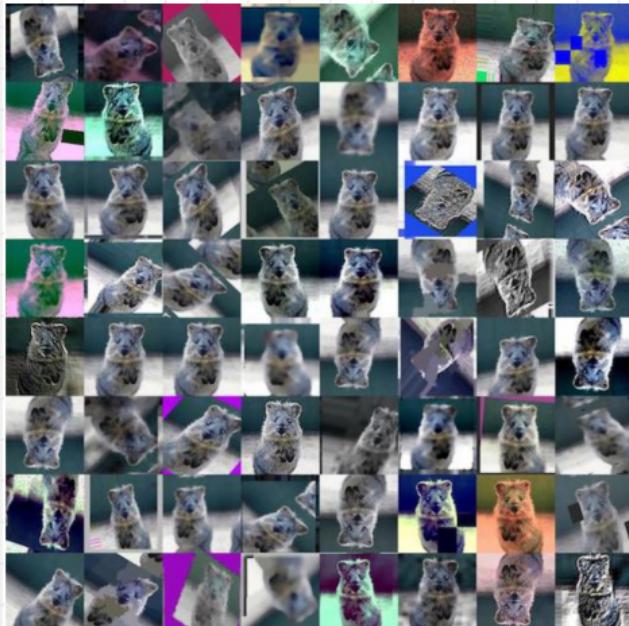


Data augmentation

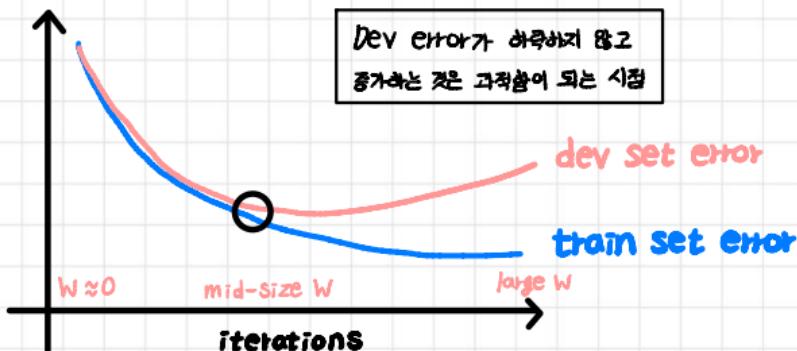


- Random Horizontal Flip
- Random vertical Flip
- Random Affine
- Random Crop
- Random Resized Crop
- Random Gray Scale
- Random Rotation
- ⋮
- ⋮
- ⋮

정규화 기법과 비슷한 효과를 냄

출처 : <https://www.kakaobrain.com/blog/64>

Early Stopping



조기종료는 개발세트의 오차가 꾸준할 때 훈련을 멈추는 것

→ 가장 잘 작동하는 점에서 멈추기

Orthogonalization

- Optimize cost function J

ex) gradient descent, momentum, RMSProp, Adam

- Not overfit

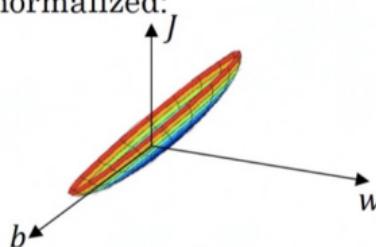
ex) regularization, more data

두 가지 작업은 별도의 원이라서 다른 방법으로 접근해야 하지만
조기종료는 두 가지 작업을 섞어버리기 때문에 최적의 조건을 찾기
어려울 수 있음

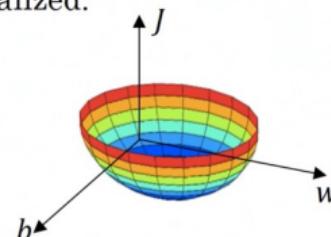
Why normalize inputs?

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m L(\hat{y}^{(i)}, y^{(i)})$$

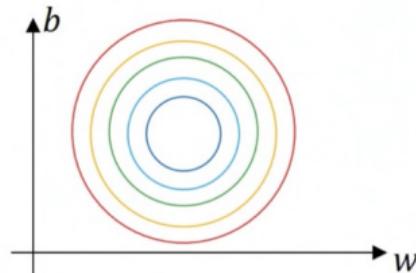
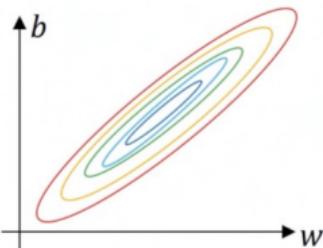
Unnormalized:



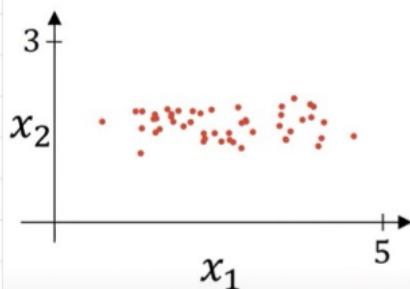
Normalized:



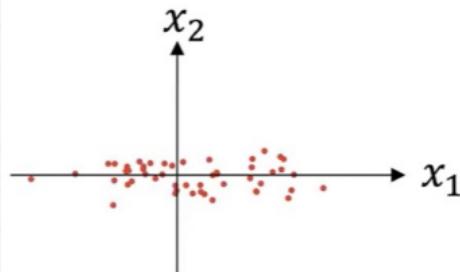
정규화를 통해 비용함수의 모양은
더 둥글고 최적화하기 쉬운 모양이 됨
→ 효율적인 학습



Normalizing training sets



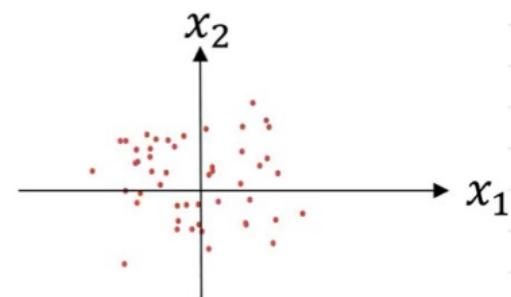
Original data



평균을 0으로 만들기

$$\mu = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$

$$x := x - \mu$$



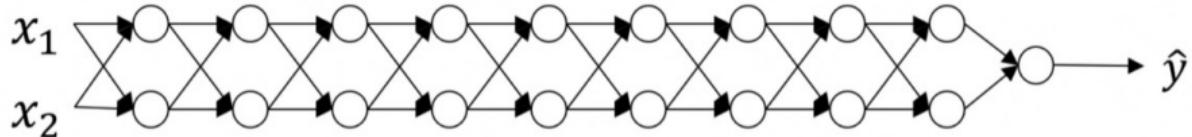
분산을 1로 만들기

$$\sigma^2 = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu)^2$$

$$x := \frac{x}{\sigma}$$

Test sets를 정규화할 때도 동일하게 정규화하기 (동일 μ, σ 사용)

Vanishing / Exploding gradients



$g(z) = z$, $b^{[1]} = 0$ 이라고 가정,

$$\hat{y} = W^{[f_1]} W^{[f_2-1]} W^{[f_3-2]} \dots W^{[s_1]} W^{[s_2]} \underbrace{W^{[s_3]} X}_{z^{[1]}}$$

$$\begin{bmatrix} 1.5 & 0 \\ 0 & 1.5 \end{bmatrix}$$

$$z^{[1]}$$

$$\begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$$

모든 가중치 행렬 $W = 1.5E$ 라고 가정하면,

$$\hat{y} = 1.5^{(1-1)} E x$$

모든 가중치 행렬 $W = 0.5E$ 라고 가정하면,

$$\hat{y} = 0.5^{(1-1)} E x$$

신경망이 깊어질수록 \hat{y} 의 값은 기하급수적으로 증가

"Exploding gradient"

신경망이 깊어질수록 \hat{y} 의 값은 기하급수적으로 감소

"Vanishing gradient"